

Análise de Sentimentos em Tweets

Nome	E-mail	Registro do Aluno
Adriano Mamoru Takeshita	10415887@mackenzista.com.br	10415887
Hideki Nakamura	hidekinakamura@gmail.com	10415167
Pedro Henrique Gonçalves Machado	pedrohmachado@gmail.com	10414885
Vitor Balduino	vdbalduino@gmail.com	10414498

1. Objetivo

O aumento do uso das redes sociais e a disponibilização de quantidades massivas de textos online fez surgir o interesse em se analisar e compreender o conteúdo disponível nos mais diversos meios. Uma das frentes de pesquisa que se encarrega de tal tarefa é a Mineração de Argumentos, cujo objetivo é identificar, extrair e compreender a estrutura argumentativa de textos online (Sousa et al. 2021). Como toda grande tarefa, a mineração de argumentos é dividida em conjuntos menores de trabalhos que podem ser realizados individualmente. Um deles — talvez o mais popular — é a análise de sentimento, que consiste em identificar se um dado documento ou pedaço de texto carrega uma conotação positiva, negativa ou neutra.

Partindo das definições acima, o objetivo do presente trabalho é executar¹ a análise de sentimentos contidos em Tweets coletados entre 01/08/2018 e 20/10/2018. Cabe ressaltar que a análise de sentimento é uma tarefa pertinente para contextos acadêmicos e não acadêmicos, possuindo grandes aplicações no setor privado (Abirami e Askarunisa 2017; Shukri et al. 2015; Souza et al. 2015).

2. Dados

A base de dados utilizada neste trabalho contém o texto dos tweets coletados no período entre 01/08/2018 e 20/10/2018, bem como uma coluna informativa da classe — positiva, negativa ou neutra — do tweet. Segundo as informações do texto de apresentação da base², a mesma foi rotulada utilizando um método de anotação distante, tomando como

¹ [Todo o trabalho foi feito em Python. Os scripts criados podem ser encontrados neste repositório do GitHub.](#)

² [A base pode ser consultada aqui.](#)

inspiração o apresentado em Go, Bhayani, e Huang (2009) e Kouloumpis, Wilson, e Moore (2011).

A base original é dividida em diversas partes menores e agregadas por tema, com o total de 900.688 tweets. Entretanto, no presente trabalho, utilizaremos a base completa e sem distinção de tópico do tweet. Nessa configuração, os dados são desbalanceados, como é possível ver na Figura 1. Inicialmente, os dados são tratados para a remoção dos usuários que fizeram o tweet ou são citados no mesmo, conversão de codificação do texto, remoção de URLs, remoção de *emoticons* e a remoção de letras repetidas em uma mesma palavra. Nesse processo, cabe notar a importância da remoção dos *emoticons*, dado que a metodologia de anotação automática da base utilizou os *emoticons* como indicadores das classes positivas e negativas. Logo, se os *emoticons* não fossem retirados, haveria um vazamento de informação entre os dados alimentados para o modelo e as classes verdadeiras, fazendo o resultado do treinamento mais positivo do que realmente seria em uma situação real com texto heterogêneo.




Figura 1. Descrição dos conjuntos de treino, validação e teste do *dataset*. Os números ao lado do título indicam a quantidade de observações em cada conjunto da base de dados.

Além do desafio que o desbalanceamento de classes oferece, é importante ressaltar a natureza do conteúdo das redes sociais. Os textos obtidos frequentemente: (i) são de baixa qualidade e/ou informais, caracterizados por erros gramaticais, abreviações e linguagem coloquial; e (ii) podem não carregar sentido semântico, devido à falta de contexto ou à ambiguidade na comunicação; e (iii) possuem um tamanho reduzido, limitando a expressão completa de ideias e nuances. A Figura 2 fornece exemplos concretos desses desafios, ilustrando a frequência de gírias e uso de expressões coloquiais, evidenciando as limitações impostas pela natureza dos dados das redes sociais.

capturar relacionamentos de longo alcance em sequências, superando as limitações das abordagens anteriores baseadas em RNNs.

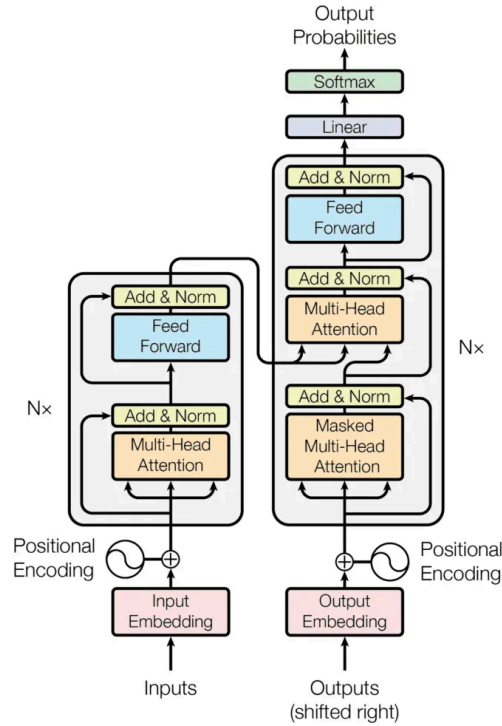


Figura 4. Arquitetura do Transformer. Retirado de Vaswani et al. (2017).

4. Resultados

Realizamos o fine-tuning do modelo utilizando a biblioteca da [HuggingFace](#) e a biblioteca [PyTorch](#). O modelo realizou 4 passagens completas no conjunto de dados (*epochs*), chegando a uma acurácia de 93,38% e um *macro f1-score* de 94,62% no conjunto de validação. Aqui a acurácia é uma métrica que informa a taxa de acerto do modelo e a *macro f1-score* é uma métrica que condensa a **precisão**³ e a **sensibilidade**⁴ do modelo em um único valor ao mesmo tempo que atribui o mesmo peso a todas as classes utilizadas. A definição matemática da acurácia e da *f1-score* estão nas Equações 1 e 2, respectivamente. Os hiperparâmetros utilizados para realizar o treinamento do modelo e que levaram a esses resultados podem ser vistos na Tabela 1. Além disso, a evolução da função de custo do modelo e da *f1-score* durante o treinamento estão na Figura 5.

³ A precisão é a taxa de acerto do modelo na classe positiva.

⁴ A sensibilidade é a taxa de verdadeiro positivo para as previsões do modelo.

$$Acurácia = \frac{Previsões\ Corretas}{Total\ de\ Previsões} \quad (1)$$

$$F1 - Score = 2 \times \frac{precisão \times sensibilidade}{precisão + sensibilidade} \quad (2)$$

Tabela 1. Hiperparâmetros utilizados para inicializar o treinamento do modelo

Taxa de Aprendizagem	$5e^{-5}$
Regularização L_2	$\frac{1}{100}$
Regularização <i>Dropout</i>	$\frac{1}{10}$
<i>Epochs</i>	4

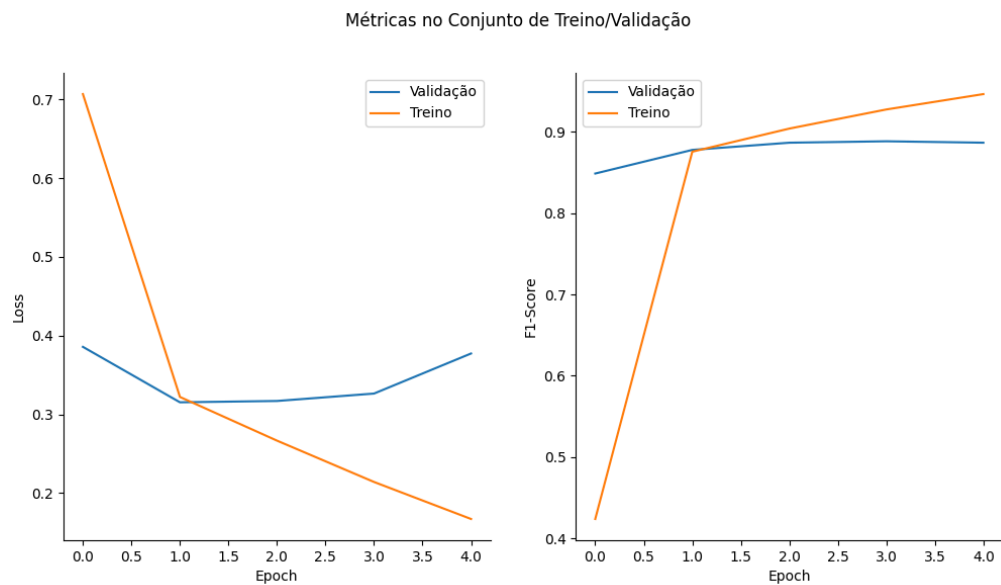


Figura 5. Métricas observadas durante o treinamento do modelo. Uma *epoch* representa uma passagem completa pelo conjunto de dados.

Por fim, como vemos na Figura 5, o aumento da distância entre as curvas da *f1-score* no conjunto de treino e validação indica que houve um sobreajuste do modelo após o final da primeira passagem pelo conjunto de dados, isto é, o modelo passou a *decorar* os dados vistos após a primeira passagem pelo conjunto de dados. A despeito disso, o resultado do modelo no conjunto de teste foi satisfatório e as métricas obtidas podem ser vistas na Tabela 2.

Tabela 2. Métricas do modelo no conjunto de teste

Função de Custo	Acurácia	<i>F1-Score</i>	Precisão	Sensibilidade
0,32	87,04%	88,90%	89,39%	88,79%

5. Proposta de Aplicação

Considerando os resultados expostos acima, tomemos o exemplo de uma empresa de varejo de roupas que queira melhorar o serviço de atendimento em suas lojas. Através da monitoração de redes sociais, a empresa poderia coletar as menções a sua marca e passá-las ao modelo para que esse realize a classificação das mensagens. De posse dos textos classificados, a empresa pode observar as reclamações mais frequentes nas mensagens negativas para identificar as lojas e etapas do atendimento que precisam de melhoria. Além disso, a empresa poderia identificar as lojas associadas aos comentários positivos para propor remuneração bônus aos funcionários daquela franquia, incentivando os mesmos a manterem o bom trabalho.

Assim, a aplicação de um modelo de análise de sentimentos permite à empresa não apenas reagir de maneira mais eficaz às insatisfações dos clientes, mas também reconhecer e recompensar os aspectos positivos do seu atendimento. Essa abordagem baseada em dados fornece ideias valiosas para a tomada de decisões estratégicas, promovendo um ciclo contínuo de melhoria e satisfação do cliente. Em última análise, a empresa se beneficia de uma maior lealdade do cliente e uma reputação fortalecida no mercado.

6. Referências

- Abirami, A. M., e A. Askarunisa. 2017. “Sentiment analysis model to emphasize the impact of online reviews in healthcare industry”. *Online Information Review* 41(4):471–86. doi: 10.1108/OIR-08-2015-0289.
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, e Kristina Toutanova. 2019. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. P. 4171–86 em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, organizado por J. Burstein, C. Doran, e T. Solorio. Minneapolis, Minnesota: Association for Computational Linguistics.
- Go, Alec, Richa Bhayani, e Lei Huang. 2009. “Twitter sentiment classification using distant supervision”. *CS224N project report, Stanford* 1(12):2009.
- Kouloumpis, Efthymios, Theresa Wilson, e Johanna Moore. 2011. “Twitter Sentiment Analysis: The Good the Bad and the OMG!” *Proceedings of the International AAAI Conference on Web and Social Media* 5(1):538–41. doi: 10.1609/icwsm.v5i1.14185.
- Shukri, Sarah E., Rawan I. Yaghi, Ibrahim Aljarah, e Hamad Alsawalqah. 2015. “Twitter sentiment analysis: A case study in the automotive industry”. P. 1–5 em *2015 IEEE Jordan Conference on Applied Electrical Engineering and Computing Technologies (AEECT)*.
- Sousa, João Pedro da Silva, Rodrigo Costa Uchoa do Nascimento, Renata Mendes de Araujo, e Orlando Bisacchi Coelho. 2021. “Não se perca no debate! Mineração de Argumentação em Redes Sociais”. P. 139–50 em *Anais do Brazilian Workshop on Social Network Analysis and Mining (BraSNAM)*. SBC.

- Souza, Fábio, Rodrigo Nogueira, e Roberto Lotufo. 2020. “BERTimbau: Pretrained BERT Models for Brazilian Portuguese”. P. 403–17 em.
- Souza, Thársis Tuani Pinto, Olga Kolchyna, Philip C. Treleaven, e Tomaso Aste. 2015. “Twitter Sentiment Analysis Applied to Finance: A Case Study in the Retail Industry”.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, e Illia Polosukhin. 2017. “Attention is All you Need”. em *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc.